Universidad Nacional de Colombia

Sede Medellín

Ingeniería Ontológica – 3010090

Trabajo Práctico 1 - Valor: 25%

Sistema RAG basico: LLMs, LangChain y LangGraph

Profesor: Jaime Alberto Guzmán Luna

Fecha de Entrega: sábado 28 de febrero, Hora de cierre: 7:50 am.
Fecha de Sustentación: sábado 28 de febrero de 10:00 am a 1:00 pm.

INTRODUCCIÓN

Esta práctica tiene como fin la aplicación de los tres temas básicos vistos en clase: Transformers/LLMs, Agentic AI (LangChain y LangGraph) y RAG. El estudiante debe seleccionar un dominio de aplicación (salud, agricultura, turismo, arte, educación, historia, etc) y construir un sistema RAG orientado al análisis inteligente de documentos.

OBJETIVO GENERAL

Diseñar e implementar un sistema de Recuperación Aumentada por Generación (RAG) capaz de responder preguntas en lenguaje natural sobre un corpus documental, mediante un flujo estructurado construido con LangChain y LangGraph integrando los modelos LLM Gemini y Groq de forma diferenciada.

OBJETIVOS DE APRENDIZAJE

1. Construir pipelines RAG de extremo a extremo.

2. Implementar grafos de ejecución con LangGraph.
3. Integrar modelos de embeddings y bases vectoriales.
4. Controlar alucinaciones mediante grounding (información externa confiable como las bases vectoriales de documentos).
5. Diseñar mecanismos básicos de evaluación automática.
6. Registrar evidencia de cómo se produjo una respuesta.

DESCRIPCIÓN DETALLADA DEL SISTEMA A DESARROLLAR

1. **Construcción del corpus**
   - Seleccionar un dominio con mínimo 50 documentos (PDF/TXT/HTML), tales como reglamentos, manuales técnicos, normas, artículos, etc.
2. **Consumo e Indexación**
   - Cargar los documentos (PDF/TXT/HTML) que conforman el dominio seleccionado
   - Limpiar texto, segmentar en chunks y generar embeddings.
   - Indexar información en una base vectorial (FAISS, Chroma u otra).
3. **Clasificación de Consultas**
   - El sistema debe identificar si la pregunta del usuario en lenguaje natural corresponde a una de las siguientes cuatro categorías:
     - Búsqueda de consumo: Solicita hechos o datos específicos contenidos en los documentos mediante lenguaje natural.
     - Resumen: Requiere hacer un resumen de uno o varios documentos.
     - Comparación: Solicita contrastar secciones/documentos.
     - Consulta General: No requiere acceso al corpus ni a la recuperación de la base vectorial. Se realizará una pregunta directa a un LLM seleccionado en diseño.
   - Alcance del proceso:
     - Determinar si la consulta requiere búsqueda semántica.
     - Identificar si el usuario desea un resumen o comparación de documentos.
     - Detectar si la consulta puede resolverse sin RAG llamando al LLM seleccionado (intención de respuesta general).

   • Este proceso en particular deberá usar un **LLM** (seleccionado por el diseñador), el cual permita una capacidad de interpretación profunda del lenguaje y comprensión contextual.

4. **Búsqueda Semántica (Recuperación)**
   - Ejecutar la búsqueda semántica usando la base vectorial.

- Seleccionar los documentos (fragmentos) más relevantes configurando top-**k** y la estrategia de similitud:
    - Usar un **LLM** (seleccionado por el diseñador) para realizar la selección dinámica de **k**.

5. **Generación de Respuesta**
    - Construye una respuesta basada únicamente en el contexto recuperado combinando:
        - La consulta del usuario.
        - Los documentos (fragmentos) recuperados más "citas".
    - Para las "citas" se requiere que el pipeline preserve metadatos (doc_id, página, chunk_id). Esto es una extensión directa de **LangChain Document metadata** (investigar).
6. **Verificación / Crítica (Evaluación)**
    - Evalúa si la respuesta generada:
        - Está respaldada por el contexto recuperado (información de documentos).
        - Es coherente y libre de alucinaciones.
        - Cumple con los requerimientos del usuario (nivel de completitud).
    - En caso de fallo, solicita nueva respuesta al agente RAG (loop controlado).
    - Este agente deberá utilizar un **LLM** (seleccionado por el diseñador), para las tareas de razonamiento y validación compleja que se requiere.
7. **Trazabilidad**
    - El sistema debe mostrar: documentos recuperados, fragmentos, metadatos, prompt final enviado al modelo y resultado de verificación.

USO DIFERENCIADO DE LLMs

Se hará uso de los LLMs Gemini y Groq en los agentes donde se requiere el uso de un LLM. Se deberá hacer un análisis y presentar la respectiva justificación de cual LLM se usará y el porque es mejor para esa actividad.

FLUJO GENERAL DEL SISTEMA

1. Usuario.

2. Clasificación de la consulta.

3. Si intención ∈ {búsqueda, resumen, comparación}:

- Recuperación → Respuesta → Evaluación.

- Si la respuesta no es adecuada → regeneración de respuesta.

4. Si intención = general:

   - Responder directamente con el LLM respectivo (asociado a clasificación).

5. Se retorna la respuesta final con trazabilidad completa.

REQUISITOS ESPECÍFICOS

1. Implementar **al menos 5 herramientas (Tools)** apropiadas para ser usadas en las actividades del sistema.
2. LangGraph debe utilizarse para representar el flujo como nodos de procesamiento (las transiciones son predefinidas, no autónomas).
3. Hacer uso en la implementación de LangChain 1.0 o superior en lo referente a Agentic AI (tools/routing/memoria/structured output)
4. Procesar y analizar documentos reales.

ENTREGABLES

1. Código fuente de la implementación Agentic AI. Deberá incluir comentarios por función y explicación del flujo general.
2. Carpeta con documentos (PDF/TXT/HTML) utilizados: 50.
3. Informe técnico del sistema RAG que incluya su diseño y registros de ejecución. Se incluirán la documentación de al menos 10 casos de uso que muestren las funcionalidades solicitadas del sistema. Igualmente deberá incluir la explicación del porqué se seleccionó Gemini y Groq en cada uno de los agentes donde se indicaba el uso de un LLM. Deberá ser un documento PDF.

SUSTENTACIÓN

1. Se realizará de manera presencial durante el horario de la clase. Durante esta se debe mostrar el funcionamiento completo del sistema y explicar:
    - La explicación clara del problema
    - Cómo se estructuraron los componentes del sistema RAG (funcionalidades y sus requerimientos)
    - La demostración funcional del sistema con sus casos de uso.

- Se debe hacer una pequeña presentación en PowerPoint para soportar la presentación
- Se realizará una sesión de preguntas (10 min de sustentación y 5 min de preguntas).
- Todos los integrantes deben estar presentes en la sustentación y se podrá seleccionar uno cualquiera para responder preguntas.

METODOLOGÍA DE EVALUACIÓN

1. Código: 60%
2. Documentación: 20%
3. Sustentación y atención a preguntas: 20%

MATERIAL POR ENTREGAR

Se deberá entregar en Google Classroom un archivo ZIP (con el siguiente nombre del archivo: practica1-grupo-XX–equipo-YY.zip, donde XX representa el número del grupo (1 o 2) y YY el número del equipo) que contenga lo siguiente:

- **Informe técnico:** Descripción detallada del sistema RAG, junto con la justificación de las decisiones tomadas en cada parte del programa.
- **Código Fuente:** Todo el programa en Python, debidamente organizado y documentado.
- **Carpeta con documentos:** Documentos (PDF/TXT/HTML) utilizados: 50.

ANEXO 1

INSTRUCCIONES GENERALES PARA LA PRESENTACIÓN DE LOS TRABAJOS

- Los trabajos serán presentados en grupos de 3 personas definidos al inicio del semestre (ver grupos en el material de la semana 2).
- **No se admiten trabajos similares (incluyendo el planteamiento del dominio)**, en caso de presentarse programas con códigos similares serán anulados. La totalidad del trabajo solicitado al alumno, en esta evaluación práctica, deberá ser original y propio del autor que lo presenta.
- La sustentación del trabajo se realizará en la fecha indicada por parte de todos los estudiantes del grupo y las preguntas orales deben ser atendidas por los estudiantes a criterios del profesor.

NOTA: La redacción de este documento de práctica puede presentar algunos errores o la ausencia de algunos requisitos específicos, los cuales deberán ser informados por parte de los estudiantes al profesor, para ser aclarados de manera colectiva durante la clase. Estas aclaraciones harán parte de los requisitos de la práctica.